

## Laboratorio 7: Ingeniería de Datos

Con relación al desarrollo y entrega del taller, tenga en cuenta lo siguiente:

- El desarrollo del taller se debe llevar a cabo en grupos de máximo 3 personas.
- El uso de herramientas de inteligencia generativa durante el desarrollo del taller está estrictamente prohibido.
- La solución del taller debe ser subido al link disponible en bloque neón antes del fin de clase.
- Todo el taller debe desarrollarse en un único archivo .ipynb que deberá tener el código pedido y la respuesta a cada una de las preguntas del taller.
- No se calificarán envíos posteriores a esta fecha y hora.
- Cualquier sospecha de fraude será manejada de acuerdo con el reglamento de la Universidad.

Usted trabaja como analista de datos para una plataforma digital de entretenimiento y recomendación de contenidos. El equipo de ingeniería de datos ha extraído un conjunto de datos mediante web scraping desde IMDb y Netflix. La base de datos (movies.xlsx) contiene 1.000 títulos de películas y series de televisión, caracterizados por las siguientes variables:

| Variable | Tipo     | Descripción                                                                           |
|----------|----------|---------------------------------------------------------------------------------------|
| MOVIES   | Texto    | Nombre de la película o serie de televisión.                                          |
| YEAR     | Texto    | Año o rango de emisión (ej. '(2021)', '(2010–2022)', '(2020– )').                     |
| GENRE    | Texto    | Género o lista de géneros separados por comas.                                        |
| RATING   | Númérico | Calificación promedio de la audiencia (1.1 a 9.9).                                    |
| ONE-LINE | Texto    | Breve sinopsis o descripción del contenido para primera impresión.                    |
| STARS    | Texto    | Cadena compuesta con director y reparto principal (ej. 'Director: ... — Stars: ...'). |
| VOTES    | Texto    | Número de votos de la audiencia almacenado como texto con comas (ej. '885,805').      |
| RUNTIME  | Númérico | Duración de la producción en minutos.                                                 |
| GROSS    | Texto    | Recaudación mundial en millones de dólares (ej. '\$0.01M').                           |

La plataforma de entretenimiento busca consolidar un catálogo limpio, consistente y confiable para alimentar sus futuros motores de recomendación y análisis de contenido. Para lograrlo, el equipo de analítica debe diagnosticar la calidad de la información en sus dimensiones fundamentales:

1. Construya dos nuevas variables llamadas DIRECTOR y REPARTO usando la información de la variable STARS ¿qué ventajas tiene contar con estas variables por separado? ¿Qué preguntas podríamos responder con esta nueva estructura de los datos que serían más difíciles de realizar utilizando la variable STARS original?
2. Al explorar la variable que contiene los títulos de las películas, se pueden encontrar algunos registros con caracteres que parecen estar alterados, por ejemplo: PokÃ©mon, McÃ²: o SaborÃ©man KantarÃ´. A partir de estos datos:
  - a) ¿Qué patrón (ej. tildes, mayúsculas, guiones) identifica en los caracteres que aparecen alterados?
  - b) ¿Qué información o evidencia adicional buscaría para determinar en qué etapa se produjo la alteración? (descarga, almacenamiento o lectura de los datos)
3. Explore las dimensiones iniciales de la base de datos y calcule el porcentaje de valores faltantes para cada columna, ¿cuál variable presenta más faltantes?
4. Determine la cantidad de registros vacíos en la duración (RUNTIME). Compare el impacto de tres estrategias de tratamiento:
  - (a) eliminar los registros nulos
  - (b) imputar mediante la media
  - (c) imputar mediante la mediana

Justifique cuál método sería el mejor

5. Cree una tabla que incluya la transformación de la variable STARS sin los duplicados y reporte las dimensiones de esta tabla, ¿cuántos duplicados hay? ¿cuál sería el mejor tratamiento para aplicar en este caso?
6. Al explorar la variable YEAR, se encuentran registros como (2006â€“2013) y (2020â€“), además de registros con un solo año. ¿Qué problemas identifica y cómo propondría limpiar o transformar esta variable para facilitar su análisis? Justifique qué haría con los rangos de años y con los registros cuyo rango está abierto.
7. En la base de datos existen registros donde RATING = 0.00. ¿Qué significado podría tener este 0? ¿Qué ocurriría si se incluyera como una calificación válida al calcular el promedio de RATING? Explique cómo determinaría si debe conservarse o tratarse como un valor faltante.
8. El equipo de marketing quiere crear la sección “Las 10 mejores producciones de la historia” ordenando la base únicamente por calificación (RATING) de mayor a menor. Al ejecutar este ordenamiento, los primeros lugares los ocupan cortometrajes desconocidos que tienen RATING = 9.8 pero solo 5 votos, dejando por debajo a clásicos como Breaking Bad. ¿Por qué confiar en una sola métrica genera un problema de calidad

en la decisión de negocio? ¿Qué criterio de combinación de variables propondría usted para que la recomendación sea realmente útil para los usuarios?